Predicția prețurilor autoturismelor

IAPD PROIECT FAZA 1
DRILEA DAN ALEXANDRU
GHIȚĂ MĂRGESCU OLIVIAN



Ideea proiectului

PROBLEMA FRAGMENTĂRII PIEȚEI

Piața auto second hand este **extrem de fragmentată**, ceea ce face dificilă găsirea unei referințe obiective pentru prețuri și caracteristici tehnice.

Achiziția datelor

OLX

Utilizăm librării precum **BeautifulSoup** pentru extragerea datelor din OLX, axându-ne pe un număr de 26.646 anunțuri.

BESTAUTO

La **BestAuto**, extragem rapid anunțuri în EUR, cu o medie de sub o secundă per anunț din 24.144 de date disponibile.

AUTOVIT

Colectăm informații din **AutoVit** folosind strategii de scraping, obținând datele de la 18.454 anunțuri structurate pe 9 segmente.

Mobil DE

Utilizam surse externe prin **MobileDE**, trecand bariera de limba si anti-scraping. Se obtin 20.000 de anunturi, pe 24 de intervale de pret.

OLX

Mecanism Anti Scrapping

Nu am putut folosi simplu **requests** datorita mecanismului antiscraping. Am folosti **culr_cffi** care impersoneaza un browser Chorme.

Maxim 25 de pagini per URL

Pentru a trece peste limitarea la 25 de pagini am parcurs masinile prin trei filter: an(2000-2026), caroserie(8) si combustibil(7)

AutoVit

Site permisiv pentru scrape

Spre deosebire de alte site-uri, AutoVit a permis o foarte usoara extragere de date prin **requests**.

Date foarte bine structurate

Site-ul prezinta o structura bogata si foarte usor de extras folosind **BeautifulSoup.** In total 35 de caracteristici.

BestAuto

Site permisiv pentru scrape, dar numar de pagini limiatat

Scrape-ul se realizeaza usor folosind **requests** si **BueatifullSoup**. Dar, site-ul prezinta doar o 100 de pagini, am realizat o segmentare pe preturi in 9 categorii.

Date neformatate sau incomplete

Am curățat valori numerice cu **expresii regulate** (kilometraj, putere și nr. cilindrii) și am dedus tipul transmisiei din descriere.

MobilDe

Strategii complexe de scrape

Am folosit **Camoufox (Stealth Firefox)** pentru a ocoli protecția **Akamai** și rotație automată de IP prin **Cloudflare WARP.**

Caracteristici incomplete

Am dedus specificațiile tehnice incomplete din titlu și descriere, iar întregul set de date a fost tradus și normalizat automat din limba germană în limba română.

Preprocesare

Gasirea coloanelor commune

Desi simbolic coloane reprezinta acelasi lucru, in fiecare set de date se pot regasi sub nume diferite, a trebuit sa indentificam si adnotam sub un nume comun fiecare coloanal in cele 4 seturi initiale.

```
Coloane comune identificate: ['body_type', 'brand', 'color', 'condition', 'doors', 'engine_capacity', 'fuel_type', 'mileage', 'model', 'powe
r', 'price', 'registered', 'title', 'transmission', 'url', 'year']
Total coloane comune: 16

Dataset unificat:
Total randuri: 89236
Total coloane: 17 <- s-a adugat coloanal sursa dupa unificare

Distributie dupa sursa:
source
OLX          26646
BestAuto     24144
MobileDe     19992
AutoVit      18454
```

Preprocesare

Eliminarea duplicatelor

Cea mai simpla metoda de indetificare a unui automobile deste dupa VIN, dar nu se regaseste in coloanele commune. Am folosit alte criterii tehnice pentru a indentifica o dublura. Dar **NU** pretul, vrem sa vedem cu fluctueaza pretul pe diferite site-uri

```
duplicate_columns = [
    "brand",
    "model",
    "year",
    "engine_capacity",
    "fuel_type",
    "power",
    "transmission",
    "mileage",
    "body_type",
    "doors"
]
```

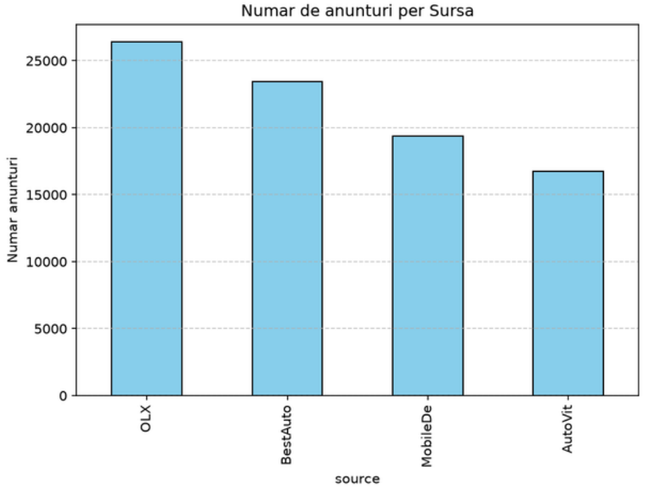
Statistici descriptive

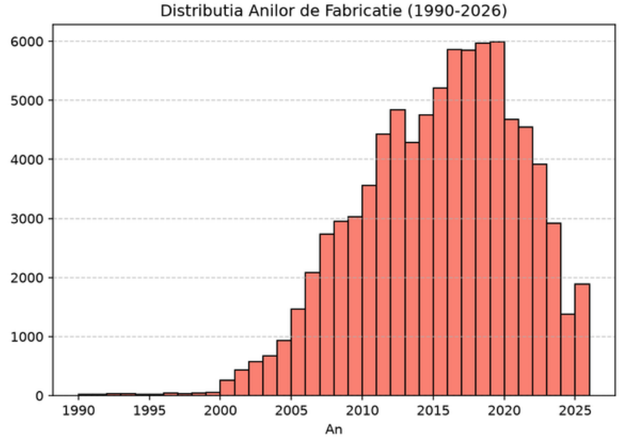
Verificam integritatea datelor

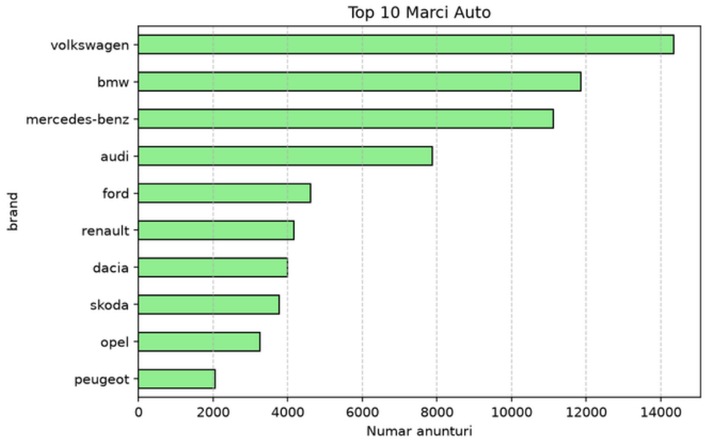
Cautam sa aflam cate valori, din fiecare categorie, are setul de date lipsa pentru a ne ajuta in antrenarea pe viitor a modelelor.

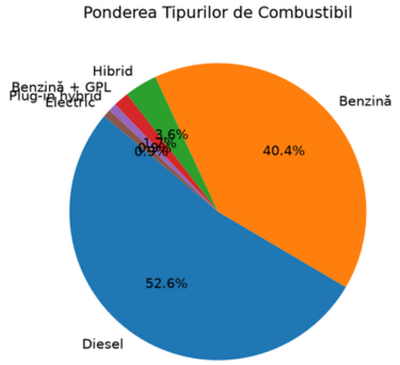
#	Column	Non-Null Count	Dtype
0	body_type	85533 non-null	str
1	brand	85290 non-null	string
2	color	55140 non-null	str
3	condition	82975 non-null	str
4	doors	67691 non-null	Int64
5	engine_capacity	83778 non-null	Int64
6	fuel_type	85687 non-null	str
7	mileage	85278 non-null	Int64
8	model	85656 non-null	string
9	power	83040 non-null	Int64
10	price	85441 non-null	float64
11	registered	73895 non-null	str
12	title	85959 non-null	str
13	transmission	75656 non-null	str
14	url	85959 non-null	str
15	year	85741 non-null	Int64
16	source	85959 non-null	str

Statistici descriptive





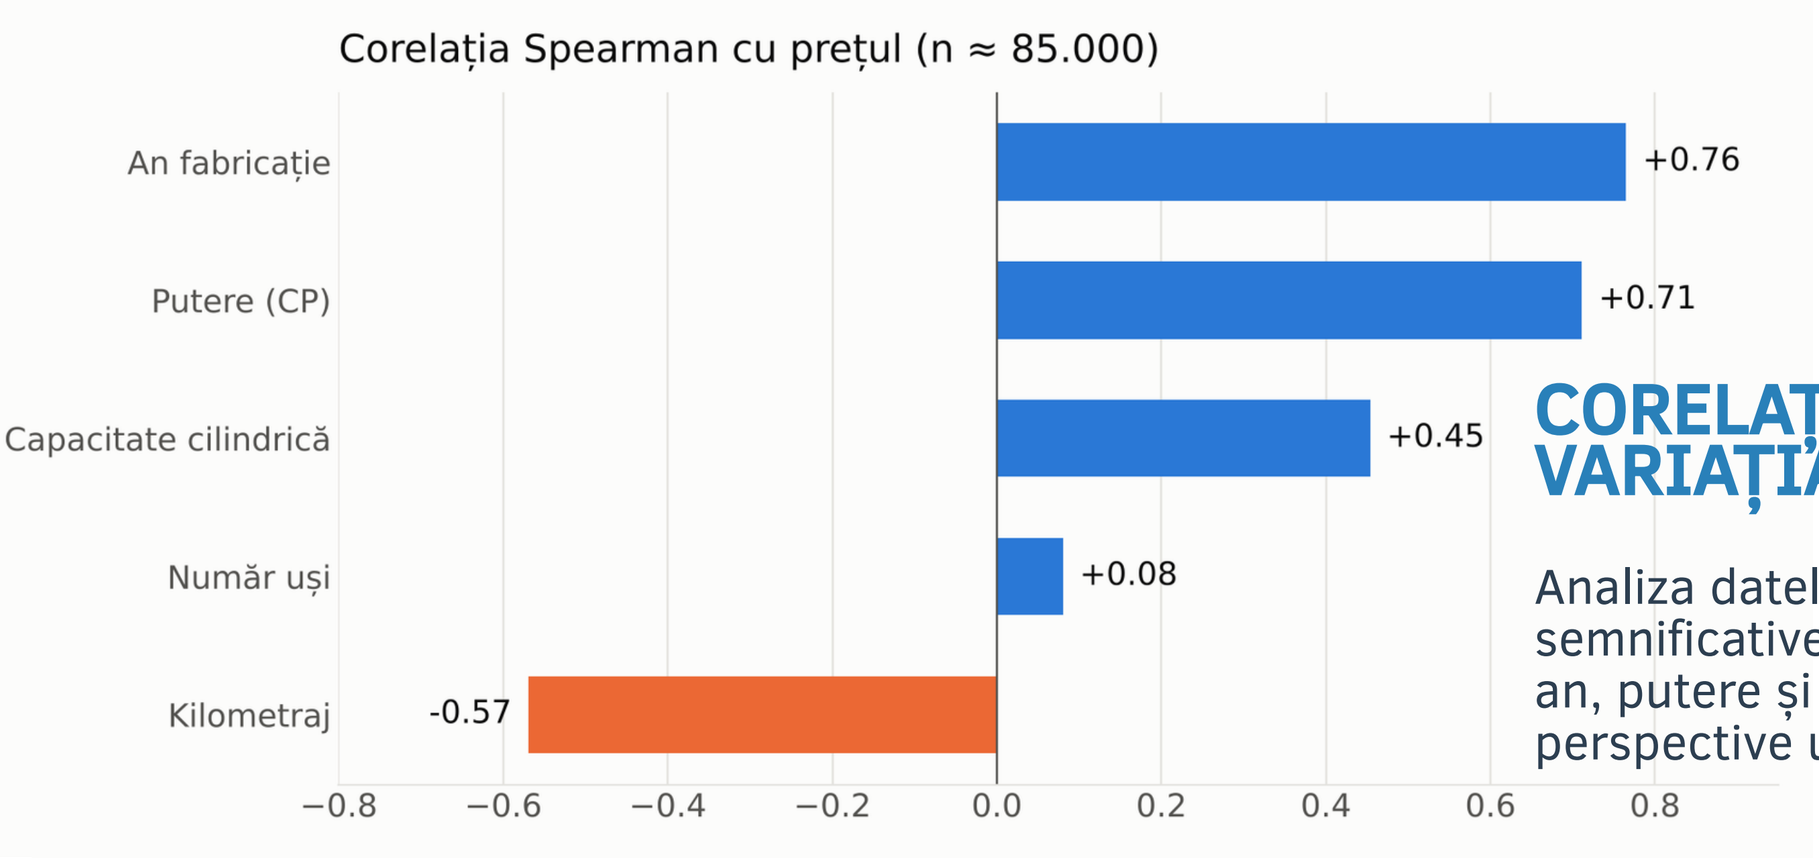




DISTRIBUȚIA PREȚURILOR AUTOTURISMELOR

Analiza a **85.959 anunțuri** arată o medie de **17.267 EUR**, cu o distribuție asimetrică, evidențiind cele mai populare mărci și modele.

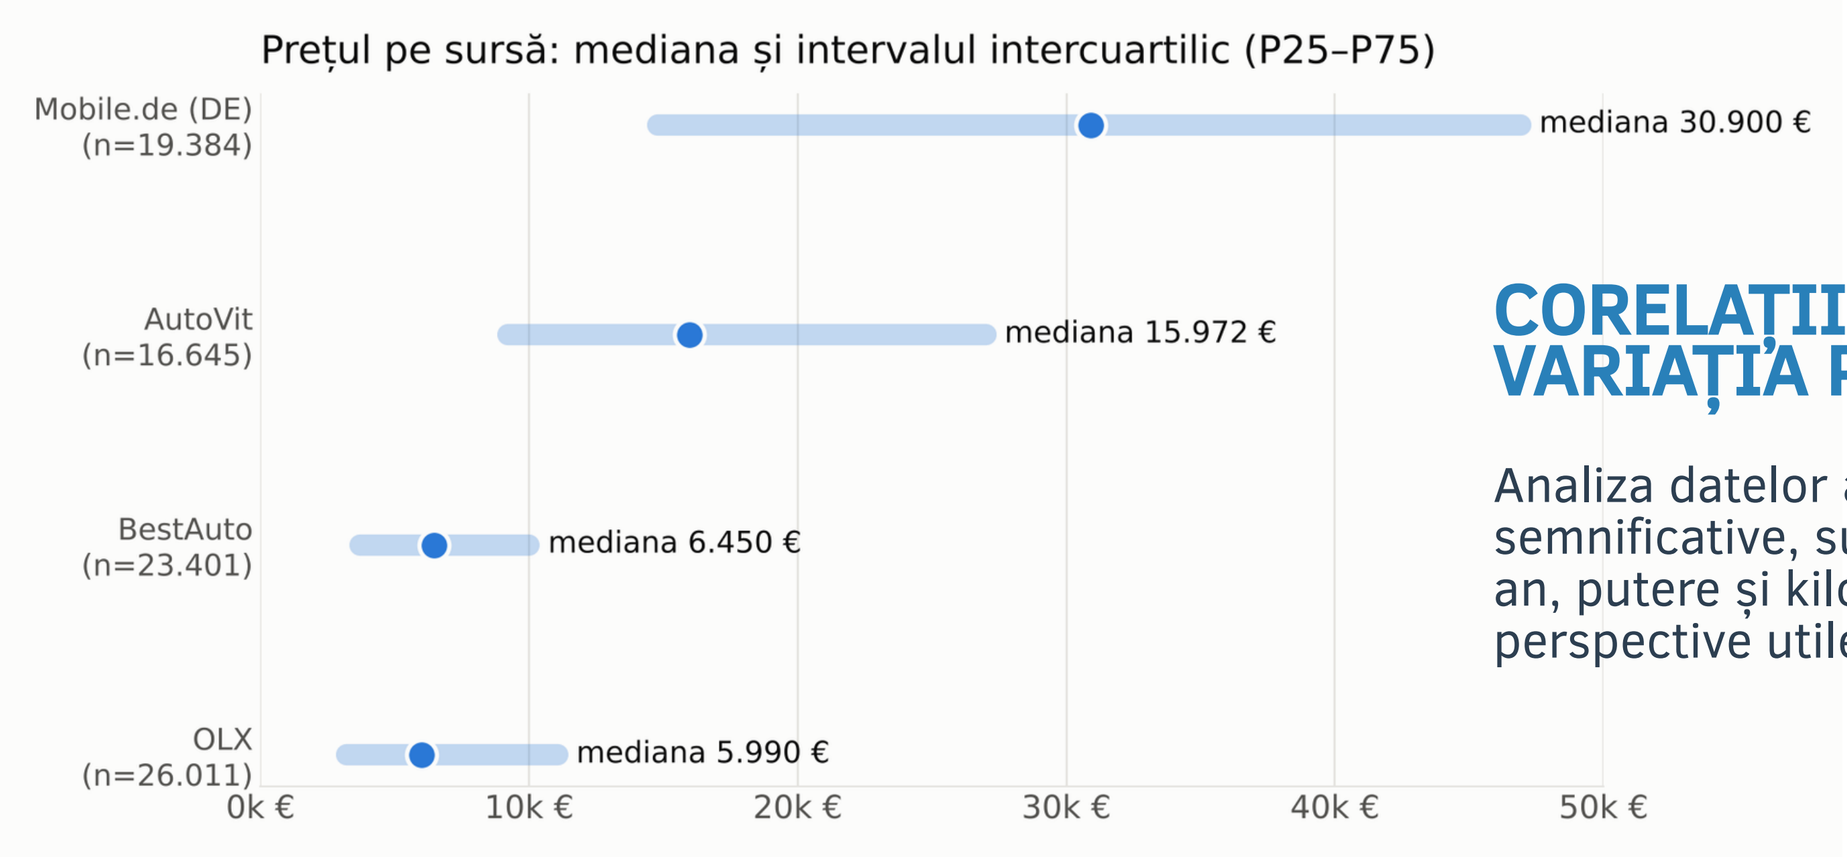
Corelații



CORELAȚII SPEARMAN ȘI VARIAȚIA PREȚULUI

Analiza datelor arată corelații semnificative, sugerând o relație între preț, an, putere și kilometraj, oferind perspective utile pentru estimări.

Variația Prețului



CORELAȚII SPEARMAN ȘI VARIAȚIA PREȚULUI

Analiza datelor arată corelații semnificative, sugerând o relație între preț, an, putere și kilometraj, oferind perspective utile pentru estimări.

Analize propuse

MODELARE

Vom utiliza regresia liniară pentru a înțelege relația dintre prețuri și caracteristicile autoturismelor second hand.

ÎMBUNĂTĂȚIRE

Predicțiile vor fi îmbunătățite prin implementarea Random Forest, care oferă o precizie superioară în estimarea prețurilor.

EVALUARE

Vom efectua evaluări cu 5 fold CV, utilizând MAE și RMSE pentru a valida eficiența modelelor dezvoltate.

Multumim pentru atentie!

DRILEA DAN-ALEXANDRU

GHITA-MARGESCU OLIVIAN